

Hacker News Digest

31/08/2026 — Top 20 articoli dal front page

20 articoli 3909 punti totali 195.4 media punti 1550 commenti totali

77.5 media commenti

Riepilogo

#	Titolo	Sito	Topic	Punti	Autore	Comm.
1	Creepy Crawlies	people.kernel.org	#ai #systems #engineering	1027	zdw	515
2	I just chose words carefully	unsung.aresluna.org	#design #ux	526	zdw	130
3	Hacking IKEA Furniture	greenlightning.eu	#design #ux	290	greenlightning	197
4	Haiku R1/beta6 has been released	haiku-os.org	#linux #systems	284	metrofun	85
5	Arbitrary code execution in QubesOS via copy-to-VM error reporting backchannel	qubes-os.org	#systems #security	217	vntok	89
6	Longest Straight Line Paths on Water or Land on the Earth (2018)	arxiv.org	#maps #data	200	joebig	58
7	Show HN: NFC Energy-Harvesting PCB Business Card with an MCU	wilsonharper.net	#esp32 #hardware	144	WilsonHarper	15

#	Titolo	Sito	Topic	Punti	Autore	Comm.
8	Coordination Headwind: How Organizations Are Like Slime Molds	komoroske.com	#career #startups	144	rzk	45
9	Startup Anti-Patterns	itamarnovick.com	#startups	124	rzk	65
10	Dad's Custom Atari Peripherals	goto10retro.com	#electronics #education	121	rbanffy	16
11	Understanding ChatGPT Work	simonwillison.net	#ai #llm	115	gmays	44
12	Sort branches by last commit date	ryangreenberg.com	#git #devtools	106	speckx	40
13	Cores in space: The core memory module from a 1980 Spacelab computer	righto.com	#aerospace #electronics	97	pwg	16
14	Zig: Pointer Stability for ArrayLists	ziglang.org	#systems #engineering	97	tosh	65
15	Why open source rocks – a new SM750 (Silicon Motion GPU) HDMI Driver	github.com	#linux #hardware	96	SillyUsername	35
16	It takes 5 cloud services to hear my doorbell	blog.vghaisas.com	#cloud #iot	86	vghaisas	65
17	Continuous Diffusion Language Models (CDLM's)	sander.ai	#ai #llm	74	peter_d_sherman	30
18	Matrox: Graphics for Professionals	abortretry.fail	#electronics #education	69	BirAdam	14
19	P99 0 ms* autocomplete for 240M domain names	ruurtjan.com	#devtools #engineering	46	dbalatero	22
20		kuleshov-group.github.io	#ai #llm	46	volodia	4

#	Titolo	Sito	Topic	Punti	Autore	Comm.
	How to build a diffusion language model					

Dettaglio Articoli

Creepy Crawlies

people.kernel.org #ai #systems #engineering **1027 punti** zdw 515 commenti

Konstantin Ryabitsev, maintainer di kernel.org, pubblica dati allarmanti sull'impatto dei crawler AI sull'infrastruttura del kernel Linux. Il dato più scioccante: il rendering HTML dei commit per gli scraper consuma più cicli CPU di tutte le altre forme di accesso legittimo messe insieme, inclusi i git clone. Su 5 nodi geograficamente distribuiti, 14 core CPU sono permanentemente occupati solo a renderizzare commit in HTML per i crawler. Ryabitsev spiega che l'intero storico dei commit del kernel Linux rappresenta una miniera d'oro per l'addestramento dei modelli di linguaggio: è facilmente filtrabile e garantisce contenuti pre-AI puri, essenziali per evitare il "digital prion disease" che affligge i modelli addestrati su output di altri LLM. La parte frustrante è che i crawler scelgono deliberatamente il metodo più inefficiente — scraping HTML — invece di clonare direttamente i repository git, che sarebbe enormemente più veloce ed economico per tutti. L'articolo solleva una questione più ampia sulla sostenibilità delle infrastrutture open source di fronte all'avidità estrattiva dell'industria AI, e si chiede se sia giunto il momento di adottare contromisure tecniche più aggressive contro questi "parassiti digitali".

I just chose words carefully

unsung.aresluna.org

#design

#ux

526 punti

zdw

130 commenti

Marcin Wichary racconta la straordinaria storia di rs1n, un autore che alla fine degli anni '90 creò una guida testuale per Super Metroid interamente in monospace, risolvendo il problema della giustificazione del testo in modo geniale: scegliendo con cura ogni parola affinché ogni riga fosse esattamente della lunghezza giusta, senza spazi doppi. L'articolo esplora le difficoltà intrinseche della tipografia in monospace: l'allineamento a destra e la centratura sono già problematici, ma la giustificazione completa è particolarmente sgradevole perché gli spazi troppo larghi non possono essere distribuiti uniformemente. La sillabazione, soluzione standard nella tipografia tradizionale, in monospace risulta visivamente invasiva e rovina il copia-incolla. La guida di rs1n rappresenta un tour de force artigianale: ogni riga è stata riscritta finché le parole non si incastravano perfettamente nella larghezza disponibile. Wichary usa questo esempio per riflettere sulla cura maniacale che caratterizzava l'artigianato digitale prima dell'era dei tool automatici, e su come certe forme di precisione ossessiva producano risultati che nessun algoritmo di formattazione può replicare. Un inno al lavoro ben fatto e all'attenzione ai dettagli nel software.

Hacking IKEA Furniture

greenlightning.eu

#design

#ux

290 punti

greenlightning

197 commenti

Un progetto DIY documentato con grande dettaglio: l'autore, trasferitosi in una nuova casa con un ufficio dedicato, voleva un mobile che unisse la praticità di un banco da lavoro all'estetica dell'arredamento domestico. I banchi da lavoro industriali erano troppo "da garage", i mobili standard troppo poco profondi (max 40 cm), e i mobili su misura fuori budget (circa 1000€ a unità). ChatGPT ha suggerito i mobili da cucina (60 cm di profondità, ~300€), ma il design e i lati a vista non erano adatti. La soluzione è arrivata dagli scaffali IKEA Kallax, già usati in passato con un pannello MDF non fissato. L'autore ha recuperato il piano della vecchia scrivania (invenduta su eBay) e lo ha montato sopra due unità Kallax, creando un piano di lavoro profondo e stabile. L'articolo include foto passo-passo, dettagli sui materiali e sull'assemblaggio, e riflessioni sull'evoluzione di IKEA come azienda: buoni prodotti nella fascia medio-bassa, disponibilità immediata, sito web funzionale con filtri precisi. Un esempio pratico di come l'hacking di mobili economici possa produrre risultati professionali a una frazione del costo.

Haiku R1/beta6 has been released

haiku-os.org [#linux](#) [#systems](#) **284 punti** metrofun 85 commenti

A due anni dall'ultima beta e una settimana dopo il 25° compleanno del progetto, Haiku rilascia R1/beta6. Haiku è un sistema operativo open source che continua l'eredità di BeOS, noto per la sua architettura elegante, il kernel modulare, il filesystem BFS con supporto per metadati estesi, e un'interfaccia grafica reattiva e coerente. Questa nuova beta rappresenta un passo significativo verso il rilascio stabile R1. Il progetto è vivo e attivo: partecipa al Google Summer of Code (3 studenti nel 2026), pubblica regolarmente report finanziari tramite Haiku Inc., e mantiene una comunità fedele. L'articolo sul sito ufficiale include i link alle release notes complete, ai download (anche per upgrade da installazioni esistenti) e ai contatti stampa. Rilasciare software di sistema di qualità in un ecosistema dominato da Linux, Windows e macOS è una sfida titanica, e Haiku continua a dimostrare che esiste spazio per sistemi operativi costruiti con una filosofia diversa: semplicità, coerenza interna e rispetto per l'utente.

Arbitrary code execution in QubesOS via copy-to-VM error reporting backchannel

qubes-os.org [#systems](#) [#security](#) **217 punti** vntok 89 commenti

Il Qubes Security Bulletin 118 rivela una vulnerabilità critica in Qubes OS: esecuzione arbitraria di codice in dom0 attraverso il meccanismo di segnalazione errori di qvm-copy-to-vm. Se un utente copia un file da dom0 verso una qube compromessa, quest'ultima può iniettare comandi arbitrari in dom0 sfruttando il protocollo qfile, in particolare il messaggio di conferma che include il nome dell'ultimo file ricevuto. Il problema sta nel fatto che il nome del file, controllato dalla qube di destinazione, viene interpolato in un comando visualizzato nell'interfaccia GUI di dom0 senza un'adeguata sanitizzazione. L'impatto è severo: un attaccante che ha compromesso una qube può prendere il controllo completo di Qubes OS se l'utente esegue qvm-copy-to-vm verso quella qube. La vulnerabilità è già stata corretta e gli utenti devono semplicemente aggiornare normalmente i loro sistemi. L'articolo include i dettagli tecnici completi e le firme crittografiche del bollettino. Un promemoria che anche i sistemi progettati con la sicurezza come principio fondante possono contenere falle inaspettate nei meccanismi di comunicazione inter-VM.

Longest Straight Line Paths on Water or Land on the Earth (2018)

arxiv.org [#maps](#) [#data](#) **200 punti** joebig 58 commenti

Un articolo accademico del 2018 di Rohan Chabukswar e Kushal Mukherjee che affronta un affascinante problema di ottimizzazione geografica: determinare la massima distanza percorribile in linea retta sulla Terra senza toccare terra (navigazione) e, viceversa, la massima distanza percorribile su terra senza incontrare ostacoli d'acqua (guida). Il problema è reso estremamente complesso dalla presenza di isole, laghi e dalla natura frattale delle coste. Gli autori propongono una metodologia basata sull'algoritmo branch-and-bound per calcolare entrambi i percorsi. Il paper è stato sottomesso alla sezione History and Overview di arXiv (math.HO) e ha generato un certo interesse sia nella comunità scientifica che sui social media, incluso un blog link. La ricerca unisce matematica computazionale, geografia e visualizzazione dati, dimostrando come problemi apparentemente semplici ("qual è la rotta in mare aperto più lunga?") richiedano strumenti matematici sofisticati per essere risolti rigorosamente. Un bell'esempio di rigore accademico applicato a una curiosità geografica.

Show HN: NFC Energy-Harvesting PCB Business Card with an MCU

wilsonharper.net [#esp32](#) [#hardware](#) **144 punti** WilsonHarper 15 commenti

Wilson Harper presenta un biglietto da visita su PCB che non ha batteria: si alimenta esclusivamente tramite energy harvesting NFC quando viene avvicinato a uno smartphone, attivando 21 LED animati. Il progetto è nato come esperimento per imparare KiCad, ma si è evoluto in tre mesi di approfondimento su ogni aspetto del processo PCB. A differenza dei classici biglietti da visita su circuito stampato (che usano solo serigrafia e rame esposto per dettagli grafici), questo incorpora un microcontrollore e sfrutta chip NFC avanzati come l'NXP NTAG I2C Plus o l'STMicro ST25DV-KC, capaci di raccogliere energia dal campo magnetico emesso dal telefono. L'articolo spiega i fondamenti dell'NFC, le sfide dell'energy harvesting (la potenza disponibile è minima), e il percorso di progettazione dall'idea iniziale al prodotto finito, con repository completo su GitHub. Un progetto che unisce ingegneria RF, design PCB, embedded programming e un pizzico di marketing personale. Dimostra che anche un biglietto da visita può essere un oggetto tecnologico sorprendente.

Coordination Headwind: How Organizations Are Like Slime Molds

komoroske.com

#career

#startups

144 punti

rkz

45 commenti

L'articolo propone un'analogia sorprendente tra le organizzazioni umane e le muffe mucillaginose (slime molds): entrambi i sistemi affrontano un problema fondamentale di coordinamento che l'autore chiama "coordination headwind" — la resistenza che emerge quando si cerca di allineare più agenti verso un obiettivo comune. Le muffe mucillaginose, organismi unicellulari che in condizioni di scarsità si aggregano formando strutture multicellulari complesse, offrono un modello biologico di coordinamento decentralizzato senza gerarchia. L'autore esplora come le grandi aziende sviluppino attriti interni che crescono con la dimensione: meeting, processi, allineamenti, politiche interne — tutto contribuisce a un "vento contrario" che rallenta l'esecuzione. La tesi è che comprendere i meccanismi di coordinamento delle muffe mucillaginose (segnali chimici, gradienti, comportamenti emergenti) possa ispirare strutture organizzative più efficienti, dove il coordinamento avviene per principi semplici anziché per stratificazione burocratica. Un pezzo originale di teoria organizzativa che unisce biologia e management.

Startup Anti-Patterns

itamarnovick.com

#startups

124 punti

rkz

65 commenti

Simeon Simeonov e Itamar Novick di Recursive Ventures lanciano una serie sugli anti-pattern delle startup: schemi di comportamento che, pur sembrando risposte appropriate ai problemi, producono più danni che benefici. L'idea risale al 2013, quando Simeonov notò che è più utile studiare i pattern di fallimento (anti-pattern) che le ricette di successo, perché queste ultime sono difficilmente replicabili mentre i primi sono sorprendentemente costanti. L'elenco include: Elephant Hunting (inseguire clienti troppo grandi), Ignoranza deliberata, Platform Risk (dipendere da una piattaforma altrui), "If You Build It They Will Come" (credere che il prodotto si venda da solo), Bad Revenue, Chasing the Competition, Chasing Blue Oceans, Analysis Paralysis, Founder Arrogance, Boiling the Ocean, Bridge to Nowhere, Design by Committee, Confirmation Bias, Bleeding on the Edge, Attribution Risk, e confondere esecuzione con strategia. L'articolo è il primo di una serie che includerà esempi concreti da oltre 100 startup in portafoglio e contributi di founder ospiti. Una lettura essenziale per chiunque operi nell'ecosistema startup.

Dad's Custom Atari Peripherals

goto10retro.com

#electronics

#education

121 punti

rbanffy

16 commenti

Jim Trageser racconta la storia di suo padre, ingegnere elettronico che lavorava per un contractor dell'Air Force negli anni '60 e '70 (brevettò il primo sistema anti-collisione aerea e un indicatore di velocità transonico). Il padre costruì da zero un computer CMOS KIM-I basato su 6502 partendo da un semplice schema blueprint, aggiungendo output RF per un TV RCA da 11 pollici e una porta seriale per una telescrivente surplus. Poi arrivarono un Fairchild Channel F e un Atari 400 con lettore a cassette. Il padre costruiva periferiche personalizzate per l'Atari, inclusi joystick rinforzati perché il gioco "Decathlon" (il famigerato "Joystick Killer") distruggeva i controller originali durante la gara dei 1500 metri. L'articolo è un ritratto affettuoso dell'era in cui l'elettronica domestica era un'attività pratica e creativa, dove un ingegnere poteva modificare e migliorare l'hardware di consumo con le proprie mani. Nostalgia pura per l'età dell'oro del retrocomputing domestico, quando il confine tra consumatore e maker era ancora tutto da esplorare.

Understanding ChatGPT Work

simonwillison.net

#ai

#llm

115 punti

gmays

44 commenti

Simon Willison analizza ChatGPT Work, il nuovo prodotto OpenAI annunciato a luglio 2026 e in rapida evoluzione. Willison distingue due versioni: Work Cloud (accessibile via chatgpt.com e app mobile, esegue task nel cloud) e Work Local (integrato nell'app desktop ex-Codex, accede a file e programmi locali). Work è disponibile solo per abbonati da \$20/mese in su, escludendo utenti free e Go. L'interfaccia presenta un selettore Chat/Work: Chat per risposte e brainstorming, Work per task con outcome definito (brief, deck, analisi, workflow). Willison trova questa distinzione poco utile, dato che usava già Chat per quegli scopi. La vera differenza sta nelle capacità esclusive di Work: esecuzione prolungata, accesso a strumenti multipli, capacità di operare in modo più autonomo. L'articolo riflette l'approccio analitico e pragmatico di Willison, che testa sistematicamente le funzionalità per capire cosa funziona davvero. Una guida essenziale per orientarsi nel panorama confuso dei prodotti OpenAI in rapida evoluzione.

Sort branches by last commit date

ryangreenberg.com [#git](#) [#devtools](#) 106 punti speckx 40 commenti

Ryan Greenberg condivide un TIL (Today I Learned) che farà risparmiare tempo a molti sviluppatori: Git supporta nativamente l'ordinamento dei branch per data dell'ultimo commit. Per anni ha usato uno script complesso con 'git branch', 'sed', 'git log' e 'sort' per visualizzare i branch più recenti. La soluzione moderna è semplicemente 'git config branch.sort committerdate' (o 'git branch --sort committerdate' per uso one-off). L'articolo esplora anche altri campi di ordinamento interessanti dalla manpage di git-for-each-ref: authordate, creatordate, taggerdate, contents:size (dimensione in byte del messaggio di commit), push, refname (default), upstream. Greenberg, sviluppatore con background in filosofia (Notre Dame) passato per Twitter, Slack e Tern, incarna il classico profilo HN: ingegnere riflessivo che condivide scoperte pratiche. L'articolo, pubblicato sul suo blog personale costruito con Astro, è breve ma denso di utilità concreta — il tipo di contenuto che rende HN una risorsa quotidiana essenziale per chi scrive codice.

Cores in space: The core memory module from a 1980 Spacelab computer

righto.com [#aerospace](#) [#electronics](#) 97 punti pwg 16 commenti

Ken Shirriff, maestro del reverse engineering storico, esamina il modulo di memoria a nuclei magnetici del computer Mitra 125 MS che equipaggiava lo Spacelab europeo negli Space Shuttle degli anni '80. Il computer francese, diverso dagli IBM AP-101 degli Shuttle, usava memoria a nuclei di ferrite anziché silicio: 128 kilobyte di RAM dove ogni bit era immagazzinato in un minuscolo anello magnetico. Shirriff ha smontato fisicamente il modulo, fotografando la stack di memoria composta da sette schede (driver, quattro piani di core, due schede di sensing) che occupavano un terzo del computer. Lo Spacelab conteneva tre computer Mitra identici: uno per il laboratorio, uno per gli esperimenti, uno di backup. Il raffreddamento era a conduzione, con il modulo di memoria saldamente ancorato al pannello laterale. L'articolo include foto dettagliate e diagrammi della NASA (C-1976-4380). Un pezzo affascinante di archeologia informatica che celebra l'ingegneria di un'epoca in cui l'affidabilità contava più della densità, e ogni bit aveva una rappresentazione fisica tangibile.

Zig: Pointer Stability for ArrayLists

ziglang.org #systems #engineering 97 punti tosh 65 commenti

Il devlog ufficiale di Zig documenta l'introduzione del Pointer Stability per gli ArrayList, un meccanismo di sicurezza della memoria che estende agli ArrayList quanto già implementato per gli HashMap nel 2024. L'idea, originariamente proposta da Leo Emar-Kar nel 2025 e implementata da Robbie Lyman, introduce `lockPointers()` e `unlockPointers()`: quando si memorizza un puntatore a un elemento di un ArrayList, si blocca il puntatore per prevenire riallocazioni che lo invaliderebbero. L'articolo mostra un esempio concreto: un parser che memorizza righe come slice in un ArrayList di history; quando history cresce oltre la capacità, le slice diventano dangling pointer. Il bug è sottile ma catastrofico. La soluzione di Zig è elegante: lock espliciti che prevengono la crescita dell'ArrayList mentre i puntatori sono attivi, con unlock per ripristinare il comportamento normale. Un esempio della filosofia Zig: massimo controllo con sicurezza verificabile, senza garbage collector né reference counting. Il devlog è parte della serie ufficiale che traccia l'evoluzione del linguaggio.

Why open source rocks – a new SM750 (Silicon Motion GPU) HDMI Driver

github.com #linux #hardware 96 punti SillyUsername 35 commenti

Un nuovo driver DRM/KMS Linux per il chip GPU SM750 di Silicon Motion, sviluppato da KodeMunkie come progetto open source. Il driver supporta HDMI, dithering RGB565 personalizzato, accesso DMA e modalità ultrawide scalate via software. La SM750 è una GPU embedded prodotta da Silicon Motion, usata in sistemi embedded e industriali. L'articolo celebra il potere dell'open source: un singolo sviluppatore può creare un driver per hardware che altrimenti resterebbe senza supporto Linux, beneficiando l'intera comunità. Il driver è sperimentale ma già funzionale, e il repository GitHub include documentazione, istruzioni di build e dettagli tecnici sui registri della GPU. Un esempio concreto di come l'open source colmi i vuoti lasciati dai produttori di hardware, specialmente nel settore embedded dove il supporto Linux è spesso trascurato. La SM750, pur non essendo una GPU di fascia consumer, rappresenta l'hardware "dimenticato" che tiene in funzione sistemi critici in tutto il mondo.

It takes 5 cloud services to hear my doorbell

blog.vghaisas.com #cloud #iot 86 punti vghaisas 65 commenti

Vivek Ghaisas racconta la sua odissea nella domotica dopo aver comprato un campanello Blink economico per la sicurezza domestica. Il problema: il campanello suona fuori dalla porta, non dentro casa, e le notifiche sul telefono non funzionano per la moglie che non lo porta sempre con sé. La soluzione avrebbe dovuto essere semplice — far suonare i Google Home Mini quando il campanello suona — ma le due piattaforme non comunicano. Dopo giorni di ricerche (nemmeno GPT-4 ha aiutato), Ghaisas ha costruito una Rube Goldberg machine digitale: il campanello Blink attiva una routine Alexa, che accende una lampadina virtuale su Samsung SmartThings (1 bit di informazione!), che a sua volta viene rilevata da Home Assistant su un mini PC, che finalmente attiva i Google Home. Cinque servizi cloud per un'operazione che dovrebbe richiederne zero. L'articolo è un'esilarante critica allo stato della domotica e all'assurda complessità creata dai giardini recintati delle piattaforme IoT. Come dice la moglie: "È davvero stupido, Vivek. Aggiungere un campanello ha reso più difficile aprire la porta agli ospiti."

Continuous Diffusion Language Models (CDLM's)

sander.ai #ai #llm 74 punti peter_d_sherman 30 commenti

Sander Dieleman, ricercatore di DeepMind, analizza la rinascita dei modelli di diffusione continui per il linguaggio. Dopo anni in cui i modelli di diffusione discreti avevano soppiantato gli approcci continui, una serie di pubblicazioni recenti sta riportando in auge l'idea che la diffusione continua possa funzionare anche per il testo. Dieleman offre una prospettiva storica: i modelli autoregressivi dominano il NLP perché decompongono naturalmente la generazione in passi sequenziali, permettono un training parallelo efficiente con teacher forcing, e hanno dimostrato scaling laws favorevoli. Tuttavia hanno limiti intrinseci: nessuna correzione d'errore, generazione esclusivamente left-to-right. La diffusione continua opera in uno spazio latente continuo e permette generazione iterativa con raffinamento globale, potenzialmente superiore per compiti che richiedono coerenza a lungo raggio. L'articolo (44 minuti di lettura) è tecnico ma accessibile, e si chiude con una domanda provocatoria: la diffusione potrebbe essere la via verso modelli più intelligenti, o è solo un vicolo cieco accademico?

Matrox: Graphics for Professionals

abortretry.fail

#electronics

#education

69 punti

BirAdam

14 commenti

Bradford Morgan White racconta la storia di Matrox, l'azienda canadese di grafica fondata nel 1976 da Lorne Trottier e Branko Matić a Dorval, Quebec. Trottier, nato nel 1948 a Montréal, appassionato di spazio ed elettronica fin da bambino (colpito dal volo suborbitale di Alan Shepard nel 1961 e dall'Apollo 11 nel 1969), conseguì un master in ingegneria alla McGill nel 1973. Con Matić iniziò a lavorare su interfacce CPU-video nel tempo libero, con la madre di Trottier come segretaria/receptionist. Il primo prodotto, il Video RAM MTX-1632 (512 byte di memoria video a 650ns, output ASCII 32x16, \$198), fu lanciato lo stesso anno e generò subito \$20.000 di ordini grazie a un annuncio sulla rivista Electronics. Il nome Matrox viene da "Ma" (Matić) e "Tro" (Trottier). L'articolo, parte della serie Abort Retry Fail dedicata alla storia dell'informatica, ripercorre l'evoluzione dell'azienda da produttrice di schede video per S-100 bus a leader nella grafica professionale, con dettagli su prodotti, prezzi dell'epoca e contesto industriale.

P99 0 ms* autocomplete for 240M domain names

ruurtjan.com

#devtools

#engineering

46 punti

dbalatero

22 commenti

Ruurtjan Pul, creatore di Wirewiki.com (strumento per ispezionare infrastrutture internet come record DNS, deleghe e configurabilità email), spiega come ha costruito un autocomplete con latenza P99 di 0 ms* su 240 milioni di nomi a dominio. L'asterisco è importante: l'articolo spiega che il trucco sta nel prefetching predittivo. Al keyDown, il sistema fa il prefetch dei suggerimenti per il carattere digitato più ogni possibile carattere successivo; al keyUp, renderizza i suggerimenti. Il risultato è una percezione di istantaneità. L'API restituisce non solo i risultati per la query corrente, ma anche un oggetto 'next' con i prefetch per la prossima lettera (a-z, 0-9, trattino, punto). Con 240 milioni di domini nel dataset, la sfida è sia di indicizzazione che di latenza di rete. L'articolo entra nei dettagli dell'implementazione, inclusa la command palette in JavaScript vanilla (nessun framework) e il design CSS. Un case study pratico su come ottimizzare la percezione di velocità quando la latenza reale non può essere eliminata.

How to build a diffusion language model

kuleshov-group.github.io

#ai

#llm

46 punti

volodia

4 commenti

Il Kuleshov Group (Cornell) pubblica un tutorial completo su come costruire un modello di linguaggio a diffusione, adattato da workshop e lezioni tenute a ICLR 2026 e MLSS 2026. L'articolo parte dal contrasto fondamentale: i modelli autoregressivi generano token uno alla volta, left-to-right, senza possibilità di correzione; la diffusione parte da rumore e raffina iterativamente l'intera sequenza. Il tutorial copre: Gaussian Diffusion di base, Masked Diffusion semplice, Block Diffusion per generazione a lunghezza variabile, architetture encoder/decoder/encoder-decoder, raffinamento iterativo con correzione d'errore integrata, accelerazione via distillation, generazione controllabile, post-training. Si chiude con una discussione su modelli di diffusione su larga scala e applicazioni in domini scientifici e biologici. La domanda finale: la diffusione è un percorso verso modelli più intelligenti? La prospettiva delle scaling laws suggerisce che potrebbe esserlo, ma il verdetto è ancora aperto. Un'introduzione tecnica eccellente per chi vuole capire l'alternativa emergente ai transformer autoregressivi.