

Hacker News Digest

2 Settembre 2026

Top 20 articoli dal front page

20 **5081** **254.1** **3144** **157.2**
ARTICOLI PUNTI TOTALI MEDIA PUNTI COMMENTI TOTALI MEDIA COMMENTI

Tabella Riepilogativa

#	TITOLO	SITO	TOPIC	POINTS	AUTORE	COMM.
1	Claude Fable 5.1 and Claude Mythos 5.1	anthropic.com	#ai	1084	denysvitali	1010
2	How accurate have Ed Zitron's AI skeptic predictions been?	danluu.com	#ai	580	jatins	657
3	Play Store blocks AuroraStore, hurting GrapheneOS users	gitlab.com	#privacy	497	erikvanoosten	206
4	Introducing Ad Blocker for Firefox on iOS	blog.mozilla.org	#privacy	383	HieronymusBosch	126
5	The ChatGPT/Codex app bundles a full copy of LibreOffice	simonwillison.net	#ai	332	timpera	150
6	Ambient CSS v3 – Blender meets CSS	ambientcss.vercel.app	#design	226	kikkupico	71
7	The creator of Jujutsu has joined ERSC	ersc.io	#git	210	steveklabnik	158
8	Ask HN: Who is hiring? (September 2026)	news.ycombinator.com	#career	206	whoishiring	225
9	Movie Scene Map – 13,312 films, series, games, anime and manga	moviescenemap.com	#maps	195	Flightmussy	30
10	Atlas: A World Model for Spatial Intelligence	worldlabs.ai	#ai	191	johnsutor	46
11	Show HN: Running 104GB Qwen3.8-Flash-Next on 48GB Mac with at ~12 tok/s	github.com	#ai	187	carloslfu	92
12	My local model setup on an M4 Pro Mac Mini	lws.io	#ai	132	raybb	63
13	Launch HN: Nori Robotics (YC S26) – A low-cost humanoid robot for development	norirobotics.com	#hardware	128	AntonioLi	43
14	FBI Probes Service Selling 153M+ Drivers Licenses	krebsonsecurity.com	#privacy	123	tatersolid	41
15	True Rate of Unemployment	lsep.org	#economics	118	pthrwns	51
16	Path to Astra: critical capabilities and frontier safeguards	openai.com	#ai	117	jithinraj	52
17	Refurbishing a Tektronix TDS7104 Oscilloscope	tomverbeure.github.io	#electronics	107	jwise0	50
18	Show HN: Weedout – Safari extension that hides YouTube AI-labeled videos	masteranza.github.io	#privacy	95	masteranza	39

#	TITOLO	SITO	TOPIC	POINTS	AUTORE	COMM.
19	Sonic Pi	sonic-pi.net	#education	86	Bluestein	14
20	The efficient frontier of LLM inference	baseten.co	#ai	84	philipkiely	20

Dettaglio Articoli

Claude Fable 5.1 and Claude Mythos 5.1

anthropic.com #ai #llm #anthropic 1084 punti denysvitali 1010 commenti

Anthropic ha annunciato Claude Fable 5.1 e Claude Mythos 5.1, gli ultimi modelli della loro famiglia di intelligenza artificiale. Si tratta dello stesso modello con livelli diversi di protezione: Fable 5.1 è disponibile per tutti, mentre Mythos 5.1 è accessibile solo tramite programmi di accesso controllato, con salvaguardie pensate per supportare la ricerca in cybersicurezza e scienze della vita. I modelli eccellono nella programmazione e nel lavoro di conoscenza, e le loro capacità di ricerca offrono un assaggio di come l'IA contribuirà al progresso scientifico. Anthropic ha inoltre risposto alle richieste degli utenti su prezzo, conservazione dei dati e salvaguardie. Le prestazioni rappresentano un nuovo standard per i modelli di frontiera, con miglioramenti significativi nel coding, nel ragionamento matematico e nella comprensione di documenti complessi. L'azienda sottolinea l'importanza della sicurezza, pubblicando una system card dettagliata che documenta le valutazioni di allineamento e i test di sicurezza condotti prima del rilascio. Con questa release Anthropic consolida la propria posizione come uno dei laboratori di IA più avanzati al mondo, competendo direttamente con OpenAI e Google nel segmento enterprise. La disponibilità di due varianti con livelli di sicurezza differenziati riflette una strategia consapevole per bilanciare accessibilità e controllo dei rischi.

How accurate have Ed Zitron's AI skeptic predictions been?

danluu.com #ai #llm 580 punti jatins 657 commenti

Dan Luu ha condotto un'analisi approfondita delle previsioni di Ed Zitron, il critico dell'intelligenza artificiale più citato nella comunità tech. Zitron ha sostenuto per anni che l'IA generativa fosse una bolla destinata a scoppiare, che i modelli non avrebbero raggiunto capacità significative e che gli investimenti miliardari fossero ingiustificati. Luu esamina sistematicamente queste affermazioni confrontandole con i fatti: i modelli hanno continuato a migliorare in modo misurabile, le aziende hanno integrato l'IA nei loro flussi di lavoro, e i ricavi del settore sono cresciuti costantemente. L'analisi non è un attacco personale ma una verifica metodica delle previsioni specifiche, e rivela un pattern di errori sistematici. Luu nota che lo scetticismo è sano, ma quando le previsioni vengono ripetutamente smentite dai dati, è legittimo chiedersi se la posizione sia ancora difendibile. L'articolo ha generato un dibattito acceso su Hacker News, con oltre seicentocinquanta commenti, toccando temi come l'hype cycle tecnologico, il ruolo dei critici nei media e la difficoltà di fare previsioni in un campo in rapidissima evoluzione.

Play Store blocks AuroraStore, hurting GrapheneOS users

gitlab.com

#privacy

#android

#decentralized

497 punti

erikvanoosten

206 commenti

Google ha apparentemente bloccato l'accesso al Play Store per Aurora Store, il client open source che permette di scaricare applicazioni Android senza un account Google. Il problema è particolarmente grave per gli utenti di GrapheneOS, il sistema operativo Android de-Google focalizzato sulla privacy, che dipendono da Aurora Store come metodo principale per installare app. Il client restituisce un errore 'Server occupato, riprova più tardi' su tutte le installazioni anonime, rendendo impossibile scaricare qualsiasi applicazione. La comunità open source sospetta un blocco intenzionale da parte di Google, che avrebbe modificato i meccanismi di autenticazione dell'API del Play Store. Aurora Store esiste da anni ed è sempre stato tollerato, ma questo cambiamento potrebbe segnalare una stretta di Google sul sideloading e sull'accesso non ufficiale al suo ecosistema. Per gli utenti di GrapheneOS, le alternative sono limitate: usare account Google (vanificando lo scopo del sistema), F-Droid (catalogo limitato), o il sideloading manuale. La discussione su Hacker News riflette la tensione tra la necessità di sicurezza di Google e il diritto degli utenti di controllare i propri dispositivi.

Introducing Ad Blocker for Firefox on iOS

blog.mozilla.org

#privacy

#design

#ux

383 punti

HieronymusBosch

126 commenti

Mozilla ha introdotto un blocco pubblicità integrato in Firefox per iOS, utilizzando la tecnologia WebKit Content Blocker di Apple e la lista di filtri EasyList. La funzione è disabilitata per impostazione predefinita e si attiva dalle impostazioni dell'app, senza bisogno di installare estensioni aggiuntive. L'Ad Blocker rimuove molti annunci di terze parti e tracker pubblicitari prima che vengano caricati, riducendo il disordine visivo e le distrazioni durante la navigazione. Mozilla specifica che non bloccherà tutti gli annunci: quelli serviti direttamente dal sito visitato e quelli nei risultati di ricerca rimarranno visibili. La funzione si affianca alle protezioni esistenti come l'Enhanced Tracking Protection. Su desktop e Android Firefox supporta già un ricco ecosistema di estensioni per il blocco degli annunci, ma iOS ha limitazioni architetturali diverse. Mozilla sottolinea il proprio impegno a mantenere un web aperto e rispettoso della privacy, offrendo agli utenti maggiore controllo sull'esperienza di navigazione senza compromettere la sostenibilità economica degli editori che dipendono dalla pubblicità non invasiva.

The ChatGPT/Codex app bundles a full copy of LibreOffice

simonwillison.net

#ai

#devtools

332 punti

timpera

150 commenti

Simon Willison ha scoperto che l'app desktop ChatGPT (precedentemente chiamata Codex) di OpenAI include una copia completa di LibreOffice, la suite open source per ufficio. Esplorando la cartella ~/.cache/codex-runtimes, Willison ha trovato 1,7 GB di dipendenze che comprendono un'installazione completa di Python, Node.js, Git, Poppler e LibreOffice. Questi componenti servono per abilitare funzionalità di elaborazione documenti: i plugin nella cartella 'documents' indicano all'app come utilizzare questi strumenti per leggere e manipolare PDF, fogli di calcolo e documenti di testo. La scoperta solleva domande interessanti sull'architettura delle app AI native: invece di delegare l'elaborazione documenti a servizi cloud, OpenAI ha scelto di includere strumenti completi localmente. Questo approccio garantisce che l'elaborazione funzioni offline e rispetta la privacy dei dati, ma aumenta notevolmente le dimensioni dell'applicazione. La comunità Hacker News ha discusso se questa sia una scelta ingegneristica pragmatica o un sintomo di 'bloat' software.

Ambient CSS v3 – Blender meets CSS

[ambientcss.vercel.app](#)

#design

#ux

226 punti

[kikkupico](#)

71 commenti

Ambient CSS v3 è un innovativo sistema di illuminazione basato sulla fisica per CSS che porta effetti di luce tridimensionale direttamente nel browser. Ispirandosi ai motori di rendering come Blender, Ambient CSS utilizza shader-like CSS per simulare luci ambientali, riflessi, ombre morbide e materiali realistici sugli elementi del DOM. Il progetto rappresenta un salto qualitativo nel web design, permettendo di creare interfacce con profondità e atmosfera che prima richiedevano WebGL o librerie JavaScript complesse. La versione 3 introduce nuovi tipi di sorgenti luminose, supporto per materiali PBR (Physically Based Rendering) e un'API più intuitiva. Gli sviluppatori possono definire scene con luci puntiformi, direzionali e ambientali, specificare proprietà dei materiali come rugosità e metallicità, e vedere il tutto renderizzato nativamente dal browser. Sebbene le performance possano essere un fattore limitante su dispositivi meno potenti, Ambient CSS dimostra il potenziale espressivo dei CSS moderni e apre nuove possibilità per interfacce immersive senza dipendenze esterne.

The creator of Jujutsu has joined ERSC

[ersc.io](#)

#git

#devtools

210 punti

[steveklabnik](#)

158 commenti

Martin von Zweigbergk, il creatore di Jujutsu (jj), è stato nominato Chief Technology Officer di East River Source Control (ERSC). Jujutsu è un sistema di version control moderno che ha guadagnato oltre trentamila stelle su GitHub, nato come progetto parallelo nel 2019 e sviluppato a tempo pieno in Google. Prima di Jujutsu, von Zweigbergk ha lavorato su Fig, il client Mercurial che permetteva agli ingegneri Google di lavorare in modo distribuito sul monorepo Piper, e ha contribuito anche a Git. ERSC sta costruendo strumenti per aiutare le organizzazioni a gestire le crescenti esigenze di gestione del codice sorgente nell'era dell'IA. Il loro prodotto ERSC Storage entrerà in beta privata a breve. Von Zweigbergk continuerà a mantenere Jujutsu come progetto open source, mentre in ERSC guiderà lo sviluppo di una nuova generazione di piattaforme di version control che vanno oltre i limiti architetturali di Git, specialmente per repository su larga scala e flussi di lavoro potenziati dall'intelligenza artificiale.

Ask HN: Who is hiring? (September 2026)

[news.ycombinator.com](#)

#career

#recruiting

206 punti

[whoishiring](#)

225 commenti

Il tradizionale thread mensile di Hacker News dedicato alle assunzioni per settembre 2026. Aziende di ogni dimensione, dalle startup in fase iniziale alle grandi imprese tecnologiche, pubblicano le loro posizioni aperte con dettagli su ruolo, tecnologie, sede e modalità di lavoro. Il thread segue il formato standard: ogni annuncio deve specificare se la posizione è remota, in sede o ibrida, con indicazione del paese quando rilevante. Sono vietate le agenzie di recruiting e i portali di annunci; solo le aziende che assumono direttamente possono pubblicare. Con oltre duecento commenti, il thread riflette lo stato del mercato del lavoro tech: si osservano molte posizioni per ingegneri AI/ML, sviluppatori full-stack, DevOps e ruoli di prodotto. L'edizione di settembre 2026 mostra un mercato dinamico ma selettivo, con aziende che cercano candidati con esperienza concreta in modelli linguistici e infrastrutture cloud. Per chi cerca lavoro nel settore tech, questo thread rimane una delle risorse più ricche e aggiornate.

Movie Scene Map – 13,312 films, series, games, anime and manga

[moviescenemap.com](#)

#maps

#data

195 punti

[Flightmussy](#)

30 commenti

Movie Scene Map è una mappa interattiva gratuita che cataloga oltre quindicimila location reali di riprese cinematografiche in centosessantasei paesi, coprendo film, serie televisive, videogiochi, anime e manga. Il progetto utilizza i dati strutturati di Wikidata come fonte primaria: ogni location è georeferenziata con coordinate, fotografia e articolo Wikipedia associato. Per i videogiochi, dove non esistono riprese reali, la mappa mostra le location narrative in cui le storie sono ambientate. L'interfaccia permette di cercare un titolo per vedere dove è stato girato, o una località per scoprire quali produzioni vi sono state realizzate. Il creatore ha costruito il sito con attenzione all'accessibilità e alla trasparenza dei dati: ogni informazione è etichettata con la fonte, e le location derivate da frasi su Wikipedia sono distinte da quelle basate su dichiarazioni strutturate di Wikidata. La mappa richiede JavaScript, ma tutte le pagine di dettaglio sono HTML puro e navigabili senza script.

Atlas: A World Model for Spatial Intelligence

[worldlabs.ai](#)

#ai

#llm

191 punti

[johnsutor](#)

46 commenti

World Labs ha presentato Atlas, un modello di mondo omni-modale progettato per l'intelligenza spaziale. Atlas è un trasformatore autoregressivo a diffusione multimodale addestrato da zero per operare nativamente su testo, immagini, video e dati 3D. Tutti gli input vengono combinati in un contesto spaziale condiviso, che il modello utilizza per generare output coerenti in tre dimensioni. Le capacità includono la generazione di video fino a un minuto a 1440p con controllo preciso della camera, la ricostruzione 3D di scene reali a partire da poche immagini superando modelli specializzati esistenti, la simulazione spazio-temporale per effetti visivi e flussi Real-to-Sim per la robotica, e la generazione di panorami a trecentosessanta gradi da descrizioni testuali. Le prestazioni di Atlas migliorano con l'aumento della computazione di addestramento, suggerendo margini di crescita significativi. Il modello rappresenta un passo avanti verso sistemi di IA con comprensione spaziale profonda, con applicazioni che spaziano dalla creatività alla robotica avanzata.

Show HN: Running 104GB Qwen3.8-Flash-Next on 48GB Mac with at ~12 tok/s

[github.com](#)

#ai

#llm

#opensource

187 punti

[carloslfu](#)

92 commenti

Slotstream è un progetto open source che permette di eseguire Qwen 3.8 Flash Next, un modello MoE da centoventicinque miliardi di parametri che occupa centoquattro gigabyte a quattro bit, su Mac con memoria RAM molto inferiore grazie a una tecnica di streaming degli esperti da SSD. Il sistema usa MLX e Swift per l'inferenza su hardware Apple Silicon, raggiungendo circa dodici token al secondo. Il principio si basa sull'architettura Mixture of Experts: invece di caricare l'intero modello in RAM, Slotstream carica solo gli esperti attivi necessari per ogni token, scaricando quelli inutilizzati su disco. Questo permette di eseguire modelli enormi su macchine con RAM limitata, come un Mac con quarantotto gigabyte. Il progetto include una API compatibile con Ollama, rendendo semplice l'integrazione con strumenti esistenti. L'autore ha implementato anche una modalità automatica che bilancia uso di memoria e velocità. L'approccio apre possibilità interessanti per l'inferenza locale di modelli di grandi dimensioni senza hardware specializzato, democratizzando l'accesso a modelli di frontiera per sviluppatori individuali e piccoli team.

My local model setup on an M4 Pro Mac Mini

lws.io

#ai

#llm

132 punti

raybb

63 commenti

Kevin Lewis descrive la sua configurazione per l'inferenza locale di modelli linguistici su un Mac Mini M4 Pro con quarantotto gigabyte di RAM. Il suo stack comprende Qwen 3.6 35B come modello principale per ragionamento e compiti complessi, e Gemma 4 E4B come modello leggero per chat semplici e formattazione. Come server di inferenza usa oMLX, mentre Tailscale connette il Mac Mini al suo iPhone e MacBook. Lewis usa Hermes come backend agente sul Mac Mini, con client desktop sul MacBook e Telegram sul telefono. Per altri utilizzi impiega Apollo su iOS e Pi come agente di coding. Le motivazioni per l'approccio locale sono chiare: indipendenza dalle API cloud, prevedibilità dei costi (risparmiando centinaia di dollari al mese), privacy dei dati sensibili e sovranità sull'IA. Lewis sottolinea il rischio operativo di inviare codice proprietario e dati clienti a servizi di terze parti, e la possibilità che i governi limitino l'accesso ai modelli. La configurazione dimostra che è possibile ottenere prestazioni paragonabili ai servizi cloud con hardware consumer.

Launch HN: Nori Robotics (YC S26) – A low-cost humanoid robot for development

norirobotics.com

#hardware

#robotics

128 punti

AntonioLi

43 commenti

Nori Robotics, startup Y Combinator S26 con sede a San Francisco, presenta Nori A3, un robot umanoide bimanuale al prezzo di milleseicentottantotto dollari. Il robot è progettato per sviluppatori e ricercatori di robotica che hanno bisogno di hardware accessibile per la raccolta dati e la sperimentazione. Nori A3 offre diciannove gradi di libertà, due braccia con sette più uno gradi ciascuna e un carico utile di un chilo e mezzo per braccio, una base con ruote differenziali, quattro telecamere RGB, lidar 2D, microfono a doppio array, e una batteria da quattrocentotrentadue wattora. Il sistema è costruito attorno a un Raspberry Pi 5 per SLAM e controlli di sicurezza, mentre i carichi computazionali più pesanti vengono eseguiti da remoto. Mantenere il prezzo sotto i duemila dollari è stata la sfida ingegneristica principale, risolta usando servo ad alto rapporto invece di motori a trasmissione diretta e una base a ruote invece che gambe. L'SDK open source include strumenti di teleoperazione e dimostrazione. Nori sa già pulire, aprire cassetti, rifornire scaffali e versare birra.

FBI Probes Service Selling 153M+ Drivers Licenses

krebsonsecurity.com

#privacy

#security

123 punti

tatersolid

41 commenti

Brian Krebs rivela che l'FBI ha aperto un'indagine su Nexus, un servizio di furto d'identità lanciato sul dark web che vende scansioni digitali di oltre centocinquanta milioni di patenti di guida di cittadini statunitensi e canadesi. Il servizio, pubblicizzato sul forum criminale russo Exploit, sembra attingere immagini raccolte da un'azienda di verifica dell'identità con sede in Louisiana. Tra i documenti in vendita compaiono patenti di alti funzionari governativi statunitensi, incluso il Segretario alla Difesa Pete Hegseth. Nexus dichiara di possedere anche oltre dieci milioni di carte d'identità, tre milioni di documenti di viaggio e quasi seicentomila carte sanitarie. Una ricerca a vuoto nel database restituisce circa undici milioni e mezzo di pagine di risultati. L'entità della violazione è paragonabile ai peggiori data breach della storia e solleva domande urgenti sulla sicurezza dei sistemi di verifica dell'identità e sulla protezione dei dati biometrici raccolti da aziende private.

True Rate of Unemployment

lisep.org

#economics

#data

118 punti

ptrhvns

51 commenti

Il Ludwig Institute for Shared Economic Prosperity (LISEP) pubblica il True Rate of Unemployment, una metrica alternativa al tasso di disoccupazione ufficiale che misura la percentuale della forza lavoro americana funzionalmente disoccupata. A differenza del dato governativo, il TRU include i lavoratori che hanno rinunciato a cercare lavoro, quelli che vorrebbero un impiego a tempo pieno ma sono costretti al part-time, e chi guadagna meno della soglia di povertà nonostante un'occupazione. A luglio 2026 il tasso di disoccupazione funzionale è salito di due decimi di punto percentuale, segnando il quarto aumento consecutivo. LISEP sostiene che le statistiche ufficiali sottostimano sistematicamente la reale difficoltà economica degli americani, mascherando la precarietà di milioni di lavoratori. L'istituto pubblica anche il True Weekly Earnings e il True Living Cost, metriche che correggono le distorsioni dei dati governativi per riflettere l'esperienza reale delle famiglie a medio e basso reddito.

Path to Astra: critical capabilities and frontier safeguards

openai.com

#ai

#llm

117 punti

jithinraj

52 commenti

OpenAI ha pubblicato il documento 'Path to Astra', che delinea le capacità critiche e le salvaguardie di frontiera per la prossima generazione di modelli di intelligenza artificiale. Il framework descrive l'approccio dell'azienda allo sviluppo responsabile di sistemi sempre più capaci, identificando soglie di rischio e contromisure per aree come la cybersicurezza offensiva, la persuasione autonoma, e le capacità di auto-replicazione e miglioramento. OpenAI propone un modello di governance a più livelli: valutazioni interne, audit esterni indipendenti, e meccanismi di controllo continuo dopo il rilascio. Il documento affronta anche la questione della proliferazione: come garantire che le capacità di frontiera non vengano utilizzate in modo malevolo una volta rese disponibili. L'iniziativa si inserisce nel dibattito più ampio sulla regolamentazione dell'IA, con l'azienda che cerca di posizionarsi come leader nella sicurezza senza rinunciare al vantaggio competitivo. La pubblicazione ha generato reazioni contrastanti: c'è chi apprezza la trasparenza e chi la considera insufficiente rispetto ai rischi sistemici.

Refurbishing a Tektronix TDS7104 Oscilloscope

tomverbeure.github.io

#electronics

#hardware

107 punti

jwise0

50 commenti

Un dettagliato resoconto del restauro di un oscilloscopio Tektronix TDS7104, strumento a quattro canali con un gigahertz di larghezza di banda e dieci gigacampioni al secondo di frequenza di campionamento. L'autore ha acquistato l'unità a un mercatino dell'elettronica nella Silicon Valley per trecento dollari, un buon prezzo considerando il valore dello strumento funzionante. Il restauro ha richiesto la sostituzione della batteria CMOS, la creazione di un'immagine del disco rigido originale, e la reinstallazione completa di Windows 2000 Pro con i driver specializzati Tektronix. Il percorso non è stato lineare: l'autore documenta tentativi falliti di passaggio a SSD, problemi di compatibilità con drive CD TEAC, e l'uso creativo di Plop Boot Manager per avviare da chiavetta USB su hardware legacy. Ogni passaggio è descritto con fotografie e note tecniche, offrendo una guida pratica per chiunque voglia restaurare strumentazione elettronica vintage. Alla fine l'oscilloscopio funziona perfettamente, con la licenza esistente riattivata e lo schermo riportato alla luminosità originale.

Show HN: Weedout – Safari extension that hides YouTube AI-labeled videos

masteranza.github.io

#privacy

#ux

95 punti

masteranza

39 commenti

Weedout è un'estensione Safari per macOS, disponibile a un dollaro e novantanove come acquisto una tantum, che rimuove i video di YouTube etichettati come 'Realizzato con IA'. L'estensione filtra i contenuti generati dall'intelligenza artificiale dal feed, dalla ricerca, dai video correlati e dagli Shorts, senza schermate di blocco o interruzioni. Il rilevamento si basa sull'etichetta di trasparenza che YouTube stesso applica ai contenuti generati con IA, evitando euristiche o falsi positivi. È disponibile anche una modalità attenuata che riduce la visibilità dei contenuti IA invece di rimuoverli completamente, permettendo all'utente di verificare prima di fidarsi. Weedout funziona interamente in locale sul Mac, senza account, tracciamento o raccolta dati. L'autore l'ha creato perché i video di cospirazione generati dall'IA stavano invadendo il suo feed YouTube. Il progetto è open source su GitHub, anche se non accetta pull request: il repository è pensato per fork indipendenti. L'estensione non cattura contenuti IA non etichettati da YouTube, ma l'autore sta valutando di estendere la copertura.

Sonic Pi

sonic-pi.net

#education

#music

86 punti

Bluestein

14 commenti

Sonic Pi è uno strumento gratuito di live coding musicale creato da Sam Aaron che permette di comporre ed eseguire musica scrivendo codice. Nato per rendere la programmazione accessibile e creativa, Sonic Pi è usato da musicisti professionisti, DJ, educatori e principianti. L'ambiente trasforma il computer in uno studio musicale completo con audio multicanale, MIDI e OSC, integrando il metronomo di rete Link di Ableton per sincronizzarsi con altri strumenti. Sonic Pi è accessibile a persone non vedenti e ipovedenti, e offre un tutorial interattivo che guida l'utente dai primi passi fino a tecniche avanzate di composizione algoritmica. Il progetto è sostenuto da una comunità attiva su Patreon e GitHub Sponsors. La filosofia alla base di Sonic Pi è che il codice possa essere uno strumento espressivo quanto uno strumento musicale tradizionale, capace di generare musica in una gamma incredibile di stili, dalla classica al jazz, dall'hip hop alla musica elettronica. Sam Aaron ha creato anche corsi ufficiali che accompagnano gli utenti nel loro percorso di live coding.

The efficient frontier of LLM inference

baseten.co

#ai

#llm

#cloud

84 punti

philipkiely

20 commenti

Philip Kiely di Baseten esplora il concetto di frontiera efficiente applicato all'inferenza dei modelli linguistici. Prendendo in prestito il termine dall'economia, l'articolo distingue due categorie di tecniche di ottimizzazione: quelle che gestiscono trade-off spostando un deployment lungo la frontiera efficienza, e quelle che spingono l'intera frontiera verso l'esterno creando più margine complessivo. Nella prima categoria rientrano il dimensionamento dei batch, le strategie di parallelismo e la quantizzazione, che permettono di bilanciare latenza e throughput in base alle esigenze. Nella seconda categoria troviamo l'ottimizzazione dei kernel, la decodifica speculativa e il disaggio (separazione delle fasi di prefill e decoding su hardware diverso), che migliorano le prestazioni assolute senza compromessi. L'articolo fornisce un quadro concettuale utile per ingegneri che devono prendere decisioni su come servire modelli in produzione, evidenziando come la scelta delle tecniche dipenda dal caso d'uso specifico: applicazioni interattive privilegiano la latenza, mentre pipeline batch richiedono throughput elevato.