

Hacker News Digest

2026-09-29 — Top 20 articoli dal front page

20 articoli · 4808 punti totali · media 240 punti · 2730 commenti totali · media 136 commenti

Tabella riepilogativa

#	Titolo	Sito	Topic	Points	Autore	Commenti
1	Sonnet 5.5	anthropic.com	#ai #llm #anthropic	703	D2OQZG8l5BI1S06	466
2	Pirating the Pirates	mubi.com	#engineering #media	501	piotrgrabowski	244
3	Jeff - Jev-compatible 0.8B decision models, trained at home, ~30 ms	github.com	#ai #llm #opensource	425	firelex	157
4	It's Time to Investigate the AI Labs	calnewport.com	#ai #regulation #philosophy	405	ibobev	145
5	Updated Google Maps shows destruction of the city of Rafah	twitter.com	#maps #data #news	385	slowin	207
6	Kids turned low-traffic NPR Spotify comments into a secret group chat	thisamericanlife.org	#web #youth #media	358	simonpure	202
7	World Labs Is Joining AMD	worldlabs.ai	#ai #hardware #business	247	mfiguiere	103
8	Hijacking the PS5's RTMP stream	yashgarg.dev	#hardware #security #gaming	233	ibobev	72
9	MicroLLM Lab - Try 7 tiny LLM's	stateofutopia.com	#ai #llm #webgpu	198	logicallee	74

**in the
browser**

10	Does Reddit have an astroturfing problem? What the data suggests	petervijeh.com	#data #platform #privacy	175	p-s-v	211
11	Show HN: HN.watch - Videos of all Hacker News posts	hn.watch	#tools #video #startup	149	mrborgen	87
12	California farmers are struggling to sell grapes as demand for wine drops	kqed.org	#agriculture #economy #news	146	randycupertino	323
13	Nvidia wants to put a watchdog chip next to every AI agent	cnn.com	#ai #hardware #business	145	jonbaer	171
14	Cf: The Agentic CLI for the Cloudflare API	blog.cloudflare.com	#cloud #devtools #ai	144	macleos	66
15	Show HN: Destroy Any Website with Stickman	destroy.spritefusion.com	#web #games #fun	126	HugoDz	32
16	12,000-year-old Göbeklitepe burials explain scattered bones	archaeologymag.com	#archaeology #science	117	yusufaytas	28
17	What reversing, modernising old games tells us about the economic impact of AI	this.os.isfine.org	#gamedev #ai #economics	102	keeda	48
18	Scientists solve 1840s	arstechnica.com	#science #space	95	gumby	42

space
weather
mystery

19	1996 chat room simulator connected to Win95 and System 7 web desktops	lolchat.rip	#retro #web #nostalgia	86	henrychannel	43
20	ESP32S3 cluster running 1.58-bit (BitNet) Language model	github.com	#esp32 #hardware #ai	68	nkko	9

Dettaglio articoli

#1

Sonnet 5.5

703 pts

anthropic.com

[#ai](#)

[#llm](#)

[#anthropic](#)

[D2OQZG8I5BI1S06](#)

[466 commenti](#)

Anthropic ha presentato Claude Sonnet 5.5, il secondo modello della famiglia Claude 5.5, presentato come un chiaro miglioramento rispetto al Sonnet 5. Il nuovo modello promette un'esecuzione oltre il trenta per cento più veloce e un costo inferiore fino al trenta per cento per la maggior parte dei carichi di lavoro. La categoria Sonnet è da tempo il compromesso tra prestazioni e prezzo nel catalogo Anthropic, pensata per l'uso produttivo quotidiano piuttosto che per i modelli di punta più grandi e costosi. Il post ufficiale sottolinea i progressi su tre fronti: prestazioni, costi e sicurezza, delineando anche i passi per iniziare a usare il modello tramite API e piattaforme. La notizia è rilevante perché mostra come la competizione tra i laboratori di frontier AI si giochi sempre più su efficienza e rapporto qualità-prezzo oltre che su capacità brute. Per le aziende che integrano l'IA, modelli più veloci e meno cari significano latenza ridotta nelle applicazioni reali e una barriera d'ingresso più bassa. La discussione su Hacker News pone l'accento su come queste metriche si confrontino con i concorrenti e su quanto il costo reale d'uso si rifletta nei benchmark.

#2

Pirating the Pirates

501 pts mubi.com #engineering #media  piotrgrabowski  244 commenti

Il lungo articolo di MUBI Notebook, firmato da Devan Scott, racconta il viaggio nel sottosuolo della preservazione cinematografica: la pratica dei bootleg e della pirateria usata come strumento di conservazione. Attraverso il caso di film come *Il buono, il brutto e il cattivo*, l'autore confronta edizioni home video diverse (Arrow Video, Kino Lorber, MGM) e mostra come versioni piratate distribuite da appassionati abbiano a volte salvato trasferimenti che le pubblicazioni ufficiali non hanno mai restituito. Il testo invita a riflettere sul fatto che la preservazione del cinema non dipende solo dagli archivi istituzionali, ma anche da una rete informale di cinefili che digitalizzano, restaurano e condividono materiale altrimenti destinato a sparire. È una riflessione sul valore culturale dei film, sulla fragilità degli sforzi commerciali e sul ruolo ambivalente del diritto d'autore: la pirateria, qui, è presentata come custode di memoria oltre che come violazione. La discussione su HN verte su etica, obsolescenza dei supporti e su come il pubblico pagante alimenti di fatto questo ecosistema parallelo.

#3

Jeff - Jev-compatible 0.8B decision models, trained at home, ~30 ms

425 pts github.com #ai #llm #opensource  firelex  157 commenti

Il progetto Jeff, su GitHub di firelex, presenta una serie di modelli di decisione (decision models) compatibili con Jev, basati su versioni fine-tunate di Qwen3.5 e Gemma 4 per classificazioni zero-shot. Il punto di forza dichiarato è la dimensione estremamente compatta: un modello da 0,8 miliardi di parametri addestrato in casa, capace di inferenze in circa trenta millisecondi. L'autore punta a modelli piccoli e veloci, addestrabili su hardware domestico, in contrasto con la corsa ai modelli giganteschi con costi di servizio milionari. I modelli di decisione sono utili per classificare testo e prendere decisioni semplici in modo rapido e localizzabile. L'articolo è interessante per chi lavora all'edge computing e all'ottimizzazione dell'IA, perché mostra un percorso alternativo: modelli specializzati e leggeri invece di LLM generalisti. La discussione su HN esplora i benchmark, la qualità delle classificazioni rispetto a modelli più grandi e il costo reale dell'addestramento.

#4

It's Time to Investigate the AI Labs

405 pts calnewport.com #ai #regulation #philosophy ibobev 145 commenti

Cal Newport interviene per chiedere che i laboratori di intelligenza artificiale di frontiera vengano finalmente indagati. L'argomento parte da una serie di comportamenti recenti che l'autore definisce audaci: annunci e report curati nei dettagli da OpenAI, volti a stabilire quanto i loro LLM siano inquietanti, potenti e potenzialmente pericolosi, con un tono sensazionalistico. Newport sostiene che la presentazione del rischio diventi una forma di marketing e di pressione politica, e che sia necessario un'indagine formale sui laboratori per capire davvero cosa fanno, come valutano la sicurezza e quali rivendicazioni siano supportate da prove. Il pezzo è un appello alla trasparenza e alla regolamentazione, in un momento in cui il settore cresce rapidamente senza una chiara supervisione. La riflessione tocca temi di governance, accountability e retorica pubblica dell'IA. Su HN il dibattito è acceso: c'è chi condivide la richiesta di scrutinio pubblico e chi difende le pratiche del settore, discutendo limiti e rischi di un'indagine.

#5

Updated Google Maps shows destruction of the city of Rafah

385 pts twitter.com #maps #data #news slowin 207 commenti

Il tweet di Ali Abunimah documenta che Google Maps ha aggiornato le proprie immagini per mostrare la distruzione della città di Rafah, nella Striscia di Gaza. Il post, con oltre tre milioni di visualizzazioni, mostra come la cartografia satellitare renda visibile in tempo quasi reale l'entità dei danni bellici: un confronto visivo, supportato da Google Maps, che illustra quartieri rasi al suolo. Il tema unisce geodata, diritti umani e copertura mediatica del conflitto in corso. Per la comunità tecnica è un esempio di come i dati geografici possano documentare eventi sul campo e alimentare dibattito pubblico: immagini satellitari aggiornate che testimoniano la guerra rendono la distruzione misurabile e difficile da negare. La discussione su HN tocca sia la dimensione emotiva e politica della vicenda sia le questioni tecniche e di affidabilità delle mappe aggiornate automaticamente. Riflessioni sull'uso dei dati cartografici come evidenza in contesti sensibili e sul ruolo delle piattaforme nel raccontare eventi geopolitici.

#6

Kids turned low-traffic NPR Spotify comments into a secret group chat

358 pts

thisamericanlife.org

#web

#youth

#media



simonpure



202 commenti

La puntata di This American Life racconta una vicenda curiosa e sconcertante: alcuni bambini hanno trasformato la sezione commenti poco trafficata del podcast NPR su Spotify in una chat segreta di gruppo. Approfittando della scarsa moderazione e del basso flusso di messaggi in quell'angolo della piattaforma, un gruppo di ragazzi ha iniziato a usare i commenti come un canale di comunicazione privato, costruendo di fatto una community nascosta dentro uno spazio pubblico e apparentemente innocuo. La storia interessa per come evidenzia l'ingegno dei giovani nel piegare le piattaforme esistenti a usi non previsti, e al tempo stesso le zone d'ombra della moderazione dei contenuti: commenti che sembrano innocui possono mascherare conversazioni parallele. È un esempio di etnografia digitale e di come i comportamenti sociali migrino gli spazi tecnologici più inattesi. Su HN il talk dibatte tra chi trova l'episodio divertente e chi sottolinea i rischi di privacy, sorveglianza e controllo per bambini e adolescenti che usano piattaforme commerciali con interlocutori sconosciuti.

#7

World Labs Is Joining AMD

247 pts

worldlabs.ai

#ai

#hardware

#business



mfiguiere



103 commenti

World Labs, la startup fondata da Fei-Fei Li dedicata all'IA spaziale e alla comprensione del mondo fisico, ha firmato un accordo definitivo per entrare in AMD. L'azienda, avviata nel 2024, porterà ad AMD le sue ricerche e i progressi tecnologici nel campo dell'intelligenza artificiale per il mondo spaziale e fisico. L'annuncio interpreta l'operazione come un'accelerazione del futuro della ricerca e del calcolo IA: unendo la visione scientifica di World Labs alle capacità hardware e infrastrutturali di AMD, l'obiettivo è scalare modelli che comprendono geometria, ambienti tridimensionali e interazioni fisiche. La mossa è strategica perché AMD punta a rafforzarsi nella corsa all'IA generativa e ai chip dedicati al calcolo, competendo con Nvidia e con i colossi integrati verticalmente. Per il settore è un segnale di consolidamento: le startup di ricerca IA più promettenti vengono assorbite dai grandi player hardware. Su HN si discute del destino dei prodotti e della tecnologia esistenti, del valore della ricerca spaziale e delle implicazioni competitive dell'acquisizione.

#8

Hijacking the PS5's RTMP stream

233 pts

yashgarg.dev

#hardware

#security

#gaming

ibobev

72 commenti

Il post del ricercatore Yash Garg documenta un progetto di reverse engineering che riesce a intercettare lo stream RTMP della PlayStation 5, riuscendo così a condividere lo schermo in modo non convenzionale. Il percorso descritto è lungo e tortuoso: parte dal problema di riuscire a fare screen sharing sulla console, passa per l'analisi di Remote Play, spiega come funziona lo streaming PS5, individua l'hostname giusto, sfrutta un trucco DNS e infine cattura lo stream per guardarlo su altri dispositivi. Sony ha progressivamente limitato ciò che è possibile fare con l'hardware della console, e questo lavoro aggira quelle restrizioni. L'articolo è tecnicamente ricco e illustra metodologie di networking debugging, packet capture e reverse engineering. Interessa sia per l'aspetto hacker-oriented sia per la discussione più ampia sulla proprietà del dispositivo e sul confine tra uso legittimo e violazione delle restrizioni. Su HN il dibattito verte sulla legalità, sulle possibilità di utilizzo pratico e sulla robustezza delle misure di protezione di Sony.

#9

MicroLLM Lab - Try 7 tiny LLM's in the browser

198 pts

stateofutopia.com

#ai

#llm

#webgpu

logicallee

74 commenti

MicroLLM Lab è un esperimento che permette di testare sette piccoli modelli linguistici direttamente nel browser, con quantizzazione Q4 e accelerazione WebGPU. L'iniziativa si inserisce nella tendenza dell'on-device AI: nessun server, nessun account, privacy totale, tutto eseguito localmente e zero costi di servizio. Gli Small Language Models (da circa venticinque a trecentosessanta milioni di parametri) vengono presentati come alternativa ultraveloce ai modelli di frontiera come GPT-4 o Claude, il cui servizio costa milioni e aggiunge latenza di rete. La piattaforma consente di eseguire, fare benchmark e confrontare questi modelli compatti direttamente nel browser. Il progetto è significativo per chi si interessa di edge computing, privacy e ottimizzazione: dimostra come modelli piccoli, opportunamente quantizzati, possano offrire funzionalità interessanti su hardware consumer senza dipendenze cloud. Su HN si discute della qualità reale dei modelli piccoli rispetto ai grandi, dei limiti hardware e del futuro di un IA distribuita e più accessibile, con meno barriere economiche per sviluppatori e utenti.

#10

Does Reddit have an astroturfing problem? What the data suggests

175 pts petervijeh.com #data #platform #privacy p-s-v 211 commenti

Il progetto di ricerca di Peter Vijeh analizza il presunto problema di astroturfing di Reddit: la pratica di account inautentici o a pagamento che lodano prodotti e marchi. L'analisi muove dall'osservazione che gli inserzionisti stanno diventando più furbi, usando bot addestrati su commenti reali per elogiare i propri prodotti, rendendo i messaggi promozionali difficili da distinguere da quelli degli utenti autentici. Il sito presenta dati e metodologie per quantificare il fenomeno, esaminando i commenti e cercando pattern riconducibili a campagne coordinate. Il tema è rilevante perché l'astroturfing mina la fiducia nelle community e nelle recensioni online, con ricadute su consumatori e piattaforme. Su HN la discussione è ampia: c'è chi mette in dubbio la robustezza della metodologia statistica, chi testimonia esperienze dirette di manipolazione e chi riflette sulle responsabilità di Reddit nel moderare o rivelare contenuti sponsorizzati. L'articolo apre interrogativi su trasparenza, algoritmi e sulla difficoltà di distinguere conversazione organica da propaganda commerciale.

#11

Show HN: HN.watch - Videos of all Hacker News posts

149 pts hn.watch #tools #video #startup mrborgen 87 commenti

HN.watch è una prova di concetto, presentata come progetto Show HN, che raccoglie in un unico posto video riguardanti tutti i post di Hacker News. L'idea è aggregare in modo organizzato i contenuti video legati alle discussioni del sito: quando un post su HN è accompagnato o collegato a un video, il servizio lo indicizza e lo rende navigabile. È uno strumento pensato per chi vuole esplorare la community in formato audiovisivo invece che solo testuale, trasformando il flusso di link e discussioni in una sorta di canale video della piattaforma. Per gli appassionati di HN, il valore sta nella comodità di una vista alternativa e nella capacità di scoprire contenuti visuali che altrimenti si perderebbero nel feed. Su HN il post raccoglie interesse per l'utilità pratica e per come è stato realizzato: c'è chi chiede dettagli tecnici sull'implementazione, sulla frequenza di aggiornamento e sulle funzionalità future, e chi discute se la categoria di prodotti aggregatori per community possieda un reale spazio di mercato.

#12

California farmers are struggling to sell grapes as demand for wine drops

146 pts

kqed.org

#agriculture

#economy

#news



randycupertino



323 commenti

Il reportage di KQED illustra una crisi concreta per l'agricoltura californiana: i viticoltori faticano a vendere l'uva mentre la domanda di vino è in calo. Le ragioni sono molteplici: il cambiamento delle abitudini di consumo, la concorrenza di altre bevande, l'eccesso di offerta e le difficoltà economiche generali. Il risultato è un eccesso produttivo con prezzi in discesa e uva invendibile, che mette sotto pressione migliaia di aziende agricole nella regione. La vicenda ha una dimensione strutturale: la California è uno dei maggiori produttori vinicoli degli Stati Uniti, e i mutamenti di mercato hanno ricadute pesanti su occupazione e territori. Per la community tecnologica l'articolo è rilevante come caso di studio economico-agricolo, e per i dati che suggeriscono sul consumo di vino tra le generazioni più giovani. Su HN la discussione affronta le cause del declino della domanda, dalle tendenze generazionali al benessere, fino alle politiche di sostegno agli agricoltori e alle conseguenze per l'industria del vino a livello globale.

#13

Nvidia wants to put a watchdog chip next to every AI agent

145 pts

cnn.com

#ai

#hardware

#business



jonbaer



171 commenti

Nvidia, secondo quanto riportato da CNBC, vuole mettere un chip di sorveglianza accanto a ogni agente di intelligenza artificiale. L'idea è affiancare alle implementazioni di agenti IA un componente hardware dedicato a monitorare e supervisionare il comportamento dei modelli, fungendo da guardiano o watchdog. Questo approccio risponde a una preoccupazione crescente: man mano che gli agenti autonomi eseguono compiti, aumenta il bisogno di controllo, tracciabilità e sicurezza per evitare azioni indesiderate. Il chip di Nvidia agirebbe come una sorta di watchdog di sistema, sorvegliando le operazioni dell'agente e aggiungendo un livello di supervisione hardware a quella software. La proposta è significativa perché tocca un tema centrale per la produzione in ambito enterprise: la fiducia e la governabilità degli agenti IA. Su HN il dibattito verte su come un simile hardware possa funzionare in pratica, sui limiti di una supervisione a livello di chip, sulle implicazioni per la sicurezza e su quanto sia genuinamente utile rispetto all'interesse commerciale di vendere più semiconduttori.

#14

Cf: The Agentic CLI for the Cloudflare API

144 pts blog.cloudflare.com [#cloud](#) [#devtools](#) [#ai](#)  maclean  66 commenti

Cloudflare ha lanciato cf, un'interfaccia a riga di comando agentica per l'intero API Cloudflare. Lo strumento promette di automatizzare operazioni complesse sulla piattaforma usando l'IA: invece di gestire manualmente singole chiamate API, l'utente descrive l'obiettivo e il CLI agentico lo esegue. La presentazione avviene durante la Birthday Week, ed è coerente con la strategia di Cloudflare che punta a strumenti per sviluppatori sempre più autonomi e integrati con l'intelligenza artificiale. Il valore per gli sviluppatori è la riduzione del lavoro ripetitivo e la possibilità di gestire configurazioni, deployment e risorse in modo più naturale. Su HN la reazione è mista ma interessata: c'è chi apprezza la direzione agentica e la visione di un'infrastruttura gestita a dialogo, e chi solleva perplessità su sicurezza, controllo e prevedibilità quando un agente agisce sull'API di un'azienda. Il dibattito tocca il futuro dei tooling per sviluppatori, l'affidabilità degli agenti autonomi e il confine tra ottimizzazione e rischio operativo.

#15

Show HN: Destroy Any Website with Stickman

126 pts destroy.spritefusion.com [#web](#) [#games](#) [#fun](#)  HugoDz  32 commenti

Destroy Any Website è un esperimento divertente di Sprite Fusion: una pagina web in cui si può digitare l'indirizzo di un sito e poi romperlo in modo giocoso. L'utente si trasforma in un omino stilizzato (stickman) che può saltare, correre, sparare e lanciare granate distruggendo gli elementi della pagina caricata. Include una demo con Wikipedia e la possibilità di creare stanze multiplayer, oltre a essere integrabile nei propri siti web. Difficoltà note: il gioco non funziona su mobile ed è pensato per laptop. È una prova creativa di come la tecnologia web possa essere usata per esperienze ludiche e distruttive, mostrando le capacità del rendering in browser e del multiplayer. Per la community è principalmente un momento di svago e curiosità tecnica, apprezzato per l'originalità e per come spinge i limiti di ciò che si può fare con le API del browser. Su HN la discussione è leggera, tra chi condivide link di siti da distruggere, chi chiede dettagli sull'implementazione e chi riflette sul valore di piccoli progetti sperimentali.

#16

12,000-year-old Göbeklitepe burials explain scattered bones

117 pts archaeologymag.com #archaeology #science yusufaytas 28 commenti

Nuovi studi archeologici gettano luce sul mistero delle centinaia di ossa umane sparse trovate a Göbeklitepe, il celebre sito neolitico in Turchia risalente a circa dodicimila anni fa. Le sepolture ritrovate aiutano a spiegare perché i resti erano sparsi: probabilmente le sepolture primarie venivano aperte e defunzionalizzate in un secondo momento, in rituali che mescolavano rispetto per i defunti e pratiche simboliche. La dispersione degli scheletri, finora enigmatica, sembra quindi il risultato di comportamenti intenzionali di una comunità che riutilizzava le tombe. Il sito di Göbeklitepe è considerato una delle più antiche strutture monumentali conosciute, e ogni scoperta ridefinisce la comprensione delle prime società umane stabili. L'articolo interessa un largo pubblico per il suo valore storico e antropologico: come vivevano e pensavano la morte le popolazioni all'alba della civiltà. Su HN la discussione verte sulla metodologia archeologica, sull'interpretazione dei rituali e sulle implicazioni per la nostra idea di vita comunitaria e religiosità preistorica.

#17

What reversing, modernising old games tells us about the economic impact of AI

102 pts this.os.isfine.org #gamedev #ai #economics keeda 48 commenti

Il post di Georg riflette sul tema dell'impatto economico del trasformatore (ovvero dell'architettura alla base dei moderni LLM), partendo da un'attività concreta: il reverse engineering e la modernizzazione di un vecchio gioco di guerra, War of the Lance del 1989. Attraverso l'esperienza di riportare in vita e aggiornare un gioco datato, con tecniche di reverse engineering e l'ausilio di strumenti di assistenza basati sull'intelligenza artificiale, l'autore trae osservazioni più ampie su come l'IA cambi l'economia dello sviluppo software. La tesi è che il trasformatore, rendendo più economiche alcune attività (scrivere codice, documentare, assistere il refactoring), sposta il valore e i costi di produzione in modi ancora non pienamente compresi. È una riflessione dal punto di vista di uno sviluppatore che osserva gli effetti concreti dell'IA sul proprio lavoro. Su HN la discussione collega esperienze personali di reverse engineering e game dev alle implicazioni macroeconomiche dell'automazione, discutendo se l'IA riduca davvero i costi in modo uniforme o concentri il valore altrove.

#18

Scientists solve 1840s space weather mystery

95 pts arstechnica.com #science #space gumby 42 commenti

Un articolo di Ars Technica, purtroppo bloccato dietro un errore 403, riferisce che gli scienziati hanno risolto un mistero meteorologico spaziale risalente agli anni 1840. Il riferimento riguarda un evento di meteorologia spaziale — come tempeste geomagnetiche o brillamenti solari — che all'epoca produsse osservazioni non riuscite dagli scienziati e solo ora, a distanza di quasi due secoli, trova una spiegazione con i dati moderni. La ricerca unisce l'analisi storica dei registri dell'Ottocento alla modellistica contemporanea dell'attività solare, mostrando come i fenomeni del passato possano essere reinterpretati con le conoscenze attuali. La notizia è rilevante per la comprensione del ciclo solare, delle aurore e delle perturbazioni geomagnetiche che possono avere effetti su reti elettriche e comunicazioni. Su HN la discussione presume il contenuto tecnico dell'articolo, richiama l'importanza della meteorologia spaziale e la difficoltà di interpretare osservazioni storiche senza strumenti accurati, sottolineando il valore dei dati d'archivio per lo studio del clima spaziale di lungo periodo.

#19

1996 chat room simulator connected to Win95 and System 7 web desktops

86 pts lolchat.rip #retro #web #nostalgia henrychannel 43 commenti

lolchat.rip è un simulatore di chat online ambientato nel 1996, eseguibile nel browser, collegato a desktop web Win95 e System 7. È un progetto nostalgico che ricrea l'esperienza delle stanze di chat e dei servizi web della metà degli anni novanta: interfaccia retrò, desktop d'epoca e l'atmosfera della prima era di Internet. L'obiettivo è far rivivere il fascino di un periodo in cui il web era più semplice e sperimentale, unendolo a una ricostruzione giocabile di OS e chat. Per chi è cresciuto in quegli anni è un tuffo nella memoria; per le generazioni più giovani, un modo interessante di capire com'era navigare nei primi tempi di Internet. Dal punto di vista tecnico, dimostra come simulazioni e frontend moderni possano ricostruire fedelmente esperienze retro. Su HN la discussione è affettuosa e nostalgica: si condividono ricordi delle chatroom, si discutono i dettagli della ricostruzione, l'autenticità delle interfacce e quanto l'esperienza online sia cambiata rispetto a trent'anni fa.

#20

ESP32S3 cluster running 1.58-bit (BitNet) Language model

68 pts

[github.com](#)

#esp32

#hardware

#ai



[nkko](#)



9 commenti

Il progetto su GitHub di Low-Zi-Hong presenta un cluster di sette nodi basati su schede ESP32-S3, capace di eseguire un modello linguistico da 0,4 miliardi di parametri utilizzando la quantizzazione ternaria a 1,58 bit (BitNet). I nodi sono collegati in daisy-chain tramite SPI e collaborano per distribuire il lavoro di inferenza. Il progetto dimostra che è possibile far girare un LLM, seppure piccolo e quantizzato, su microcontrollori a bassissimo costo, combinando più chip per raggiungere capacità maggiori di quelle di un singolo dispositivo. È un esempio estremo di edge computing: hardware accessibile ed energetico adatto a scenari a bassa potenza, pur con prestazioni limitate. L'idea è stimolante per la comunità maker e per chi lavora su IA embedded. Su HN la discussione verte sulle prestazioni reali, sui compromessi della quantizzazione estrema a 1,58 bit, sull'architettura di comunicazione SPI e su quali applicazioni pratiche possano trarre beneficio da cluster di ESP32 che eseguono modelli linguistici.